

INTRODUCTION

Le provisionnement pour sinistres est une tâche critique en assurance de dommages (IARD). Il consiste à estimer les montants futurs à verser pour des sinistres déjà survenus, mais non entièrement réglés. Une estimation précise est essentielle pour garantir la solvabilité de l'entreprise et répondre aux exigences réglementaires. La nature longitudinale des données, où un sinistre se développe sur plusieurs années, rend cette tâche complexe et idéale pour des modèles statistiques avancés.

Le Problème : Comment prédire avec la meilleure précision possible la distribution des paiements de sinistres futurs, en tenant compte de la censure des données et de l'hétérogénéité des profils ?

- 80% de dossiers sans paiement (Zero-inflation).
- Queues de distribution lourdes (Large Losses).
- Nécessité d'un *Best Estimate* robuste sous IFRS 17.




Figure 1: **Concept de l'Iceberg Actuariel** : Le ML réduit la variance locale en capturant l'hétérogénéité individuelle, là où le GLM ne fournit qu'une estimation globale moyenne (Image générée avec l'IA).

OBJECTIFS

Implémenter et optimiser trois approches de modélisation distinctes :

- Modèles Linéaires Généralisés (GLM) – Tweedie.
- LightGBM – Tweedie : performance prédictive pure.
- Modèle Hybride : classification couplée à une régression.

DONNÉES (CAS RFP 2025)

- Volume** : ~70 000 lignes de développement.
- Cible** : Paiements déflatés ($Incr_Payment_Defl$).
- Features Clés** : Volatilité des paiements, âge du sinistre, ratios de développement, etc.

Variable	Type	Rôle
Pay_Volatility	Continue	Signal de sévérité
Claim_Age	Temporelle	Maturité du dossier
Open_Ind	Binaire	Statut juridique
Rolling_Mean	Moyenne	Tendance récente

MÉTHODOLOGIE

1. GLM Tweedie (Baseline)

Modèle de référence avec $p = 1.5$. Structure rigide incapable de capturer les interactions complexes entre l'ancienneté et la volatilité.

2. LightGBM Tweedie unifié

L'algorithme champion. Optimisation de la perte Tweedie avec un paramètre de forme $p = 1.8$, favorisant la capture de la sévérité (Gamma).

3. Interprétabilité (SHAP)

Utilisation des valeurs de Shapley pour justifier les prédictions et transformer la "boîte noire" en modèle auditable.

VALIDATION CROISÉE

Stratégie de découpage temporel "Out-of-Time" pour simuler la réalité :

- Train (2009-2019)** : Apprentissage historique.
- Valid (2020-2022)** : Calibration (Inflation/COVID).
- Test (2023-2024)** : Évaluation aveugle.




Figure 2: **Courbe de Lorenz (Gini 0.753)** : Le modèle est 8x plus efficace que l'aléatoire pour isoler les sinistres coûteux.




Figure 3: **Analyse SHAP** : La volatilité des paiements est le 1er moteur de réserve, confirmant l'intuition métier : un dossier instable est un dossier cher.

RÉSULTATS FINAUX

Modèle	RMSE	Biais	Biais (adj.)
GLM Tweedie	4 039	-26.4%	-
Two-Stage Hybride	2 816	+31.9%	0.00%*
LightGBM (p=1.8)	2 594	-6.8%	-0.46%

*Le modèle Two-Stage a été recalibré par un facteur de 0.758 pour annuler son biais structurel sur cette cohorte.

DISCUSSION ACTUARIELLE

- Pourquoi Tweedie $p = 1.8$?** Cette valeur privilégie la modélisation de la sévérité, cruciale car les 20% des dossiers les plus risqués concentrent 52.6% du coût total.

- Calibration** : L'application d'un facteur IBNR de 1.0621 permet de corriger le biais structurel du Gradient Boosting sur les valeurs extrêmes.

DIAGNOSTIC ET IMPORTANCE




Figure 4: **Homoscédasticité des résidus** : La dispersion centrée sur zéro à travers les différentes échelles de prédiction confirme l'absence de biais systématique. **Distribution de l'erreur** : Une distribution symétrique et resserrée illustre la robustesse de la loi Tweedie pour traiter la masse de zéros.




Figure 5: Comparaison des paiements incrémentaux réels vs prédits par année d'accident. Cette figure illustre la capacité du modèle à reconstituer le montant total des sinistres pour l'année 2024.




Figure 6: **Gain d'information** : Classement des variables par leur contribution à la réduction de l'impureté. *Payment_volatility* domine l'année d'accident.

CONCLUSION

- Précision** : Réduction du RMSE de 35% vs GLM.
- Opérationnel** : Triaging automatisé des sinistres.
- Fiabilité** : Écart inférieur à 1% après calibration.

ACCÈS AUX ANALYSES COMPLÈTES

Pour consulter l'intégralité du code, les étapes d'optimisation et les graphiques interactifs, veuillez accéder au Notebook Colab ici : [Lien vers le Notebook Google Colab](#)

Références :

- Friedman, J. H. (2001). Greedy function approximation : A gradient boosting machine. *Annals of Statistics*, 29(5), 1189-1232.
- Chen, T., & Guestrin, C. (2016). XGBoost : A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., . . . & Liu, T. Y. (2017). LightGBM : A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*.

INTRODUCTION

Loss reserving is a critical task in Property and Casualty (P&C) insurance. It consists of estimating future payments for claims that have already occurred but are not yet fully settled. Accurate estimation is essential to guarantee the company's solvency and meet regulatory requirements. The longitudinal nature of the data, where a claim develops over several years, makes this task complex and ideal for advanced statistical models.

The Problem: How to predict the distribution of future claim payments with the best possible accuracy, taking into account data censoring and profile heterogeneity?

- 80% of cases with no payment (Zero-inflation).
- Heavy-tailed distributions (Large Losses).
- Necessity of a robust *Best Estimate* under IFRS 17.




Figure 7: **The Actuarial Iceberg Concept:** ML reduces local variance by capturing individual heterogeneity, whereas GLM only provides a global mean estimation (AI-generated image).

OBJECTIVES

Implement and optimize three distinct modeling approaches:

- Generalized Linear Models (GLM) – Tweedie.
- LightGBM – Tweedie: pure predictive performance.
- Hybrid Model: classification coupled with regression.

DATA (CAS RFP 2025)

- Volume:** ~70,000 development rows.
- Target:** Deflated payments (*Incr_Payment_Defl*).
- Key Features:** Payment volatility, claim age, development ratios, etc.

Variable	Type	Role
Pay_Volatility	Continuous	Severity signal
Claim_Age	Temporal	File maturity
Open_Ind	Binary	Legal status
Rolling_Mean	Average	Recent trend

METHODOLOGY

1. Tweedie GLM (Baseline)

Reference model with $p = 1.5$. Rigid structure unable to capture complex interactions between seniority and volatility.

2. Unified LightGBM Tweedie

The champion algorithm. Optimization of Tweedie loss with a shape parameter $p = 1.8$, favoring the capture of severity (Gamma).

3. Interpretability (SHAP)

Use of Shapley values to justify predictions and transform the "black box" into an auditable model.

CROSS-VALIDATION

"Out-of-Time" split strategy to simulate reality:

- Train (2009-2019):** Historical learning.
- Valid (2020-2022):** Calibration (Inflation/COVID).
- Test (2023-2024):** Blind evaluation.




Figure 8: **Lorenz Curve (Gini 0.753):** The model is 8x more effective than random selection at isolating costly claims.




Figure 9: **SHAP Analysis:** Payment volatility is the #1 reserve driver, confirming business intuition: an unstable file is an expensive file.

FINAL RESULTS

Model	RMSE	Bias	Bias (adj.)
Tweedie GLM	4,039	-26.4%	–
Two-Stage Hybrid	2,816	+31.9%	0.00%*
LightGBM (p=1.8)	2,594	-6.8%	-0.46%

*The Two-Stage model was recalibrated by a factor of 0.758 to cancel its structural bias on this cohort.

ACTUARIAL DISCUSSION

- Why Tweedie $p = 1.8$?** This value prioritizes severity modeling, which is crucial as the top 20% of riskiest files concentrate 52.6% of the total cost.
- Calibration:** Applying an IBNR factor of **1.0621** corrects the structural bias of Gradient Boosting on extreme values.

DIAGNOSTICS AND IMPORTANCE




Figure 10: **Residual Homoscedasticity:** Dispersion centered at zero across prediction scales confirms the absence of systematic bias. **Error Distribution:** A symmetric and tight distribution illustrates the robustness of the Tweedie law for handling zero-inflation.




Figure 11: Comparison of actual vs. predicted incremental payments by accident year. This figure illustrates the model's ability to reconstruct total claims for the year 2024.




Figure 12: **Information Gain:** Ranking of variables by their contribution to impurity reduction. *Payment_volatility* dominates the accident year.

CONCLUSION

- Accuracy:** 35% RMSE reduction vs. GLM.
- Operational:** Automated claim triaging.
- Reliability:** Gap of less than 1% after calibration.

ACCESS TO COMPLETE ANALYSES

To view the full source code, optimization steps, and interactive visualizations, please access the Colab Notebook here:
[Link to Google Colab Notebook](#)

References:

- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189-1232.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD '16 Proceedings*.
- Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 30.